
Análisis de la Demanda Energética en Tetuán: Influencia de Variables Climáticas y Patrones Cíclicos Horarios.

Karen Cardona Gutiérrez. Ingeniería de Sistemas.
karen.cardonag@udea.edu.co

RESUMEN

Resumen— Este artículo presenta un análisis completo del consumo energético en tres zonas de la ciudad de Tetuán, Marruecos, con el fin de identificar patrones temporales relevantes para apoyar la planificación y gestión de la demanda eléctrica. Se aplicó el ciclo completo de la ciencia de datos, iniciando con la transformación y organización de variables temporales, seguida de un análisis exploratorio univariado, bivariado y multivariado. El tratamiento de datos incluyó la detección cuantificada de valores atípicos mediante el método IQR y Z-Score, los cuales se conservaron al asociarse con variaciones reales del comportamiento energético. Para garantizar coherencia analítica, se aplicó estandarización y posteriormente Análisis de Componentes Principales (PCA) con el fin de reducir la dimensionalidad y abordar la multicolinealidad presente en las variables climáticas y de consumo.

Los resultados revelaron un patrón horario con picos de demanda entre las 19:00 y 21:00 horas, así como un desfase respecto a las temperaturas máximas del día. El PCA indicó que los dos primeros componentes explican más del 70% de la varianza, evidenciando estructuras latentes útiles para el modelado. En conclusión, el dataset preprocesado ofrece una base sólida para futuras tareas de predicción y para el diseño de estrategias de planificación energética más eficientes.

Palabras clave: consumo energético, PCA, patrones horarios, outliers, Tetuán.

INTRODUCCIÓN

La gestión de la energía eléctrica es un elemento clave para lograr ciudades más sostenibles y para avanzar hacia la construcción de redes inteligentes (smart grids) [1]. Para ello, resulta fundamental entender y predecir el comportamiento de la curva de carga, ya que esto permite planear mejor la operación del sistema y aprovechar de forma eficiente los recursos disponibles. En ciudades como Tetuán, Marruecos, este reto es aún más relevante, porque la demanda eléctrica cambia según las condiciones del clima y las rutinas diarias de la población.

A partir de este contexto, la investigación se orienta a responder una pregunta central: ¿Qué factores explican el consumo energético en las tres zonas de distribución de Tetuán?

Con este fin, el estudio se enfoca en dos grupos principales de variables: los factores climáticos (temperatura, humedad y viento) y los patrones temporales (especialmente los ciclos horarios), que suelen tener un impacto directo en la variación del consumo [2]. Analizar estos factores es importante porque permite distinguir qué parte de la demanda corresponde al consumo habitual y cuál surge por condiciones climáticas extremas o por los picos de uso durante el día. Para lograr un análisis confiable, es necesario depurar y transformar los datos originales, atendiendo problemas como la multicolinealidad entre las variables y la presencia de valores atípicos, que en este caso reflejan eventos reales y significativos del sistema eléctrico.

Con esta perspectiva, los objetivos del proyecto son:

-
-
- A. Realizar un Análisis Exploratorio de Datos (EDA) que permita identificar los ciclos de consumo y la relación entre el clima y la demanda energética.
 - B. Implementar un proceso de preprocesamiento que incluya la detección y el manejo justificado de outliers, así como el escalamiento de variables para garantizar la coherencia del análisis.
 - C. Aplicar Análisis de Componentes Principales (PCA) para reducir la dimensionalidad, resolver la multicolinealidad y extraer las estructuras principales que explican la variabilidad del consumo.

Finalmente, este trabajo expone los métodos utilizados, presenta los resultados obtenidos mediante análisis visual y estadístico, y demuestra que el dataset procesado es adecuado para construir modelos de predicción de la demanda eléctrica.

METODOLOGÍA

A. Fuente y Características del Conjunto de Datos

El análisis se basó en el conjunto de datos "Power Consumption of Tetouan City", obtenido del repositorio UCI Machine Learning Repository [3]. Este dataset registra el consumo de energía (en kWh) en tres zonas de la ciudad de Tetuán (Zone 1, Zone 2, Zone 3), cinco variables atmosféricas y de radiación (Temperature, Humidity, Wind Speed, general diffuse flows, diffuse flows) y una variable de tiempo (Datetime).

El conjunto inicial consta de 52,416 registros y 9 variables.

- I. Trazabilidad: En el proceso inicial de limpieza se identificó que no había registros con valores faltantes (NaN). Lo que garantizó una alta calidad de datos de entrada.
- II. Transformación de Variables: Se crearon las variables discretas Day y Hour a partir de la columna temporal original Datetime, la cual fue posteriormente eliminada para evitar redundancia y multicolinealidad.
- III. Eliminación de variables: Para concentrar el análisis en los factores climáticos directos y evitar redundancia de información en la etapa de PCA, las columnas relativas a los flujos difusos de luz (general diffuse flows y diffuse flows) fueron excluidas del análisis exploratorio y del posterior escalado. Esta exclusión se justifica en la necesidad de simplificar el espacio de características, ya que la varianza asociada a la radiación solar suele estar fuertemente correlacionada con la variable de Temperatura.

B. Técnicas empleadas en el proceso analítico

El proceso analítico se desarrolló en tres etapas que se complementan entre sí y permiten pasar de la comprensión inicial de los datos a su preparación final para métodos más avanzados.

I. Análisis Exploratorio de Datos (EDA)

En esta primera fase se utilizaron técnicas estadísticas y herramientas de visualización para entender la estructura general del dataset y sus patrones más relevantes.

Análisis univariado: Se revisó cada variable numérica por separado usando histogramas y boxplots, lo que permitió detectar distribuciones sesgadas, concentraciones en ciertos rangos y posibles valores atípicos.

Análisis bivariado y multivariado: Se construyó la matriz de correlación de Pearson para estudiar la relación entre las variables de consumo y clima. Además, se analizaron las series de tiempo para identificar patrones diarios y semanales, lo que permitió observar fenómenos clave como el desfase entre la hora de temperatura máxima y el pico de demanda eléctrica.

II. Detección y tratamiento de datos atípicos

Una vez entendida la estructura del dataset, se procedió a identificar y evaluar los outliers.

Detección y cuantificación: Para esto se empleó el método del Rango Intercuartílico (IQR), estableciendo límites de $1.5 \times \text{IQR}$ sobre Q3 y bajo Q1. Este procedimiento permitió contar exactamente cuántos valores se consideraban atípicos en cada variable.

Tratamiento: No se eliminaron ni imputaron los valores atípicos. La decisión se fundamentó en que estos valores representan situaciones reales de operación -por ejemplo, picos de temperatura o momentos de alto consumo- y eliminarlos podría distorsionar el comportamiento real del sistema. Por esta razón, se conservaron con el fin de mantener la validez del análisis y de potenciales modelos predictivos.

III. Reducción de Dimensionalidad (PCA)

Finalmente, se aplicó Análisis de Componentes Principales (PCA) sobre las variables numéricas estandarizadas. Esta técnica permitió capturar la mayor parte de la variabilidad del sistema en un número reducido de componentes ortogonales y resolver la multicolinealidad presente entre las variables climáticas.

C. Criterios de Tratamiento y Transformación de Variables

Imputación: Se realizó una revisión completa del dataset para comprobar su integridad. Se confirmó que ninguna de las 8 columnas presentaba valores faltantes, lo cual indica una recolección precisa por parte de los sensores originales.

Dado que no existían datos nulos, no fue necesario aplicar técnicas de imputación. Registrar explícitamente esta decisión permite mantener la trazabilidad del flujo de trabajo y aclarar que el preprocesamiento se centró en la transformación y el escalamiento, más que en la corrección de valores ausentes.

Escalamiento: Las variables numéricas del dataset están medidas en rangos muy distintos:

- I. La humedad puede llegar al 100%,

-
- II. La temperatura se mueve en un rango mucho más acotado,
 - III. La velocidad del viento rara vez supera los 15 m/s,
 - IV. El consumo energético tiene magnitudes aún mayores.

Si se usaran estos valores sin escalar, variables con rangos altos dominarían algoritmos basados en distancia o varianza, como el Análisis de Componentes Principales (PCA).

Se aplicó la Estandarización (StandardScaler) de Scikit-learn. porque este método ajusta cada variable a una media (μ) de 0 y una desviación estándar (σ) de 1. Esto permite que todas las variables aporten de manera equilibrada al PCA. Además, a diferencia de métodos como MinMaxScaler, la estandarización conserva la forma original de la distribución y amortigua el impacto de los outliers sin distorsionar los datos.

Transformación de Variables Categóricas:

- I. **Variable Day:** La columna que indica el día de la semana es categórica y nominal. Asignarle un código numérico implicaría introducir un orden falso (por ejemplo, “martes > lunes”), lo cual no tiene sentido desde el punto de vista analítico. En este caso, Se utilizó **One-Hot Encoding**, lo que generó variables binarias como *Day_Monday*, *Day_Tuesday*, etc., permitiendo que el modelo capture el impacto diferencial de cada día sobre el consumo sin asumir relaciones ordinales.
- II. **Variable Hour:** Aunque *Hour* es técnicamente una variable categórica cíclica (0 a 23), transformarla con One-Hot Encoding habría creado 24 columnas nuevas, lo que aumentaría innecesariamente la dimensionalidad. Por ello se tomó la decisión de mantenerla en su formato numérico, pero estandarizada.

D. Herramientas y librerías utilizadas

El análisis y el preprocesamiento se desarrollaron en Python, aprovechando un conjunto de librerías ampliamente utilizadas en ciencia de datos por su robustez y eficiencia:

Pandas y Numpy: se emplearon para la manipulación del dataset, la limpieza inicial y el manejo de arreglos y estructuras de datos. Estas librerías facilitaron la creación de nuevas variables, el filtrado de información y los cálculos necesarios para las fases exploratoria y de preprocesamiento.

Matplotlib y Seaborn: se utilizaron para generar las visualizaciones del EDA, incluyendo distribuciones, boxplots, correlaciones y patrones temporales diarios y horarios. También fueron fundamentales para la construcción del Scree Plot empleado en el análisis de PCA.

Scipy: proporcionó funciones estadísticas adicionales que complementaron el análisis exploratorio y la validación de supuestos. Aunque su uso fue puntual, resultó útil para cálculos estadísticos específicos y para respaldar la interpretación de la variabilidad y dispersión de las variables.

Scikit-learn: fue la base del preprocesamiento avanzado, especialmente para la estandarización mediante StandardScaler, el tratamiento de variables numéricas y la implementación del Análisis de Componentes Principales (PCA). Esta librería permitió garantizar que todas las variables trabajaran en la misma escala y facilitó la reducción de dimensionalidad sin comprometer la interpretación de la varianza.

RESULTADOS Y ANÁLISIS

A. Análisis Exploratorio de Datos (EDA):

La fase de Análisis Exploratorio de Datos (EDA) ha permitido desglosar la estructura de la demanda energética y su relación con las condiciones climáticas. Los hallazgos se presentan de forma estructurada, interpretando de manera crítica los patrones identificados.

I. Estructura Descriptiva y Análisis Univariado

El análisis de los estadísticos descriptivos (Tabla 1) y las distribuciones de frecuencia revela la naturaleza de las variables clave del estudio.

Tabla 1: Estadísticos Descriptivos de Variables Clave

Variable	Media	Desv. Estándar	Asimetría	Curtosis	Interpretación
Consumo Zona 1	32,345	7,131	0.229	-0.754	Consumo más alto y mayor variabilidad. Distribución ligeramente asimétrica positiva, lo que indica picos esporádicos.
Consumo Zona 2	21,043	5,201	0.329	-0.437	Consumo intermedio y más estable (menor desv. estándar). Distribución cercana a la normalidad.
Consumo Zona 3	17,835	6,622	1.024	1.086	El menor consumo promedio, pero con una asimetría y curtosis altas. Esto indica que los valores están fuertemente sesgados hacia la izquierda, con la presencia de picos extremos que distorsionan el promedio.
Temperatura (°C)	18.81	5.815	0.197	-0.303	Distribución equilibrada (simétrica) con dos picos, lo que sugiere una clara distinción entre épocas cálidas y frías a lo largo del año.
Humedad (%)	68.26	15.551	-0.625	-0.122	Alta en general, con asimetría negativa. Predominan los registros de alta humedad, un factor que puede mitigar la necesidad de refrigeración.
Velocidad del Viento	1.96	2.35	0.462	-1.783	Distribución fuertemente sesgada a la derecha, confirmando que la mayoría de los registros tienen vientos débiles, con muy pocos eventos de viento fuerte.

El análisis descriptivo permitió identificar comportamientos diferenciados entre las tres zonas de consumo energético de Tetuán y los factores climáticos asociados. La Zona 1 mostró el promedio de consumo más alto (≈ 32.3 kWh) y la mayor variabilidad, lo que sugiere una zona con actividades más intensivas o una demanda más sensible a las variaciones externas. Su ligera asimetría positiva indica la presencia de días con consumos elevados, aunque no se evidencian eventos extremos según su curtosis negativa.

La Zona 2, por su parte, presentó un comportamiento más estable, con un nivel de consumo intermedio y una distribución más equilibrada. Esto apunta a un patrón de demanda más regular, posiblemente asociado a una menor sensibilidad a los cambios climáticos o a un uso más constante a lo largo del tiempo.

En contraste, la Zona 3 registró el promedio de consumo más bajo (≈ 17.8 kWh), pero acompañada de una asimetría notablemente positiva (1.02) y curtosis también positiva (1.08). Este comportamiento refleja la presencia de picos ocasionales de alta demanda, aunque la mayoría de los datos se concentran por debajo de la media, lo cual sugiere un consumo generalmente bajo con episodios puntuales de incremento.

En cuanto a las variables climáticas, la humedad mostró un promedio elevado (≈ 68 %) y una asimetría negativa, lo que indica que los valores altos son más comunes que los bajos. La velocidad del viento presentó una media muy baja (≈ 2 km/h) y una distribución fuertemente sesgada hacia valores pequeños, evidenciando que los episodios de viento fuerte son poco frecuentes. Finalmente, la temperatura mantuvo un promedio de 18.8 °C con baja variabilidad y una distribución equilibrada, sugiriendo un clima relativamente estable durante el periodo observado.

II. Análisis Bivariado: Relaciones Climáticas y Temporales

Correlación entre Consumo y Clima

La matriz de correlación de Pearson entre el consumo y las variables climáticas establece las interdependencias lineales.

Tabla 2: Correlación entre consumo y clima

Variable	Consumo Zona 1	Consumo Zona 2	Consumo Zona 3
Temperature	0.44	0.38	0.49
Humidity	-0.29	-0.29	-0.23
Wind Speed	0.17	0.15	0.28

El análisis de correlación permitió identificar cómo influyen los factores climáticos sobre la demanda eléctrica en cada una de las tres zonas de Tetuán. En primer lugar, la **temperatura** mostró una relación positiva moderada con el consumo energético (r entre 0.38 y 0.49). Esto significa que, a medida que aumenta la temperatura, también lo hace la demanda de electricidad, probablemente por el uso intensificado de ventiladores, aires acondicionados u otros sistemas de enfriamiento. La **Zona 3** presentó la correlación más fuerte ($r = 0.49$), lo que evidencia una

mayor sensibilidad a los cambios térmicos.

En contraste, la **humedad** exhibió una correlación negativa débil a moderada (r entre -0.23 y -0.29). Este comportamiento indica que, en condiciones más húmedas, el consumo tiende a disminuir ligeramente. Una posible explicación es que la humedad elevada suele asociarse con temperaturas más estables o menos cálidas, reduciendo la necesidad de climatización artificial.

La **velocidad del viento** mostró una relación positiva muy débil (r entre 0.15 y 0.28), lo que sugiere una influencia mínima sobre el consumo. Aunque la correlación es baja, podría estar reflejando coincidencias temporales entre condiciones de viento y ciertas franjas horarias de mayor demanda.

De manera general, las tres zonas presentan patrones consistentes:

- La **temperatura** es el factor climático que más influye en el consumo, especialmente en las Zonas 1 y 3.
- La **humedad** tiende a disminuirlo ligeramente.
- El **viento** tiene un impacto marginal.

En conjunto, estos resultados confirman que el clima (particularmente la temperatura) juega un papel clave en la variabilidad de la demanda energética, lo que es fundamental para la planificación y gestión eficiente de la red eléctrica.


Patrones Cíclicos Diarios y Semanales

El análisis de series temporales desagregado por hora del día y día de la semana establece los patrones de uso.

Patrón Horario: Al examinar el comportamiento horario, se observa que la Zona 1 presenta consistentemente los valores más altos de consumo energético. Su demanda mínima ocurre entre las 5:00 y 7:00 a.m., mientras que el máximo se localiza entre las 19:00 y 21:00 horas (7–9 p.m.), lo cual sugiere un incremento asociado a actividades residenciales y comerciales nocturnas.

La Zona 2 exhibe un patrón similar al de la Zona 1, aunque con niveles de consumo intermedios. Su pico principal también se registra entre las 19:00 y 21:00 horas, lo que refuerza la presencia de un comportamiento cíclico con incrementos en horas de alta actividad.

Por otro lado, la Zona 3 es la de menor demanda energética durante todo el día. Su comportamiento horario es más estable y homogéneo, con un ligero aumento al final de la jornada, aunque sin alcanzar los valores de las otras zonas.




Patrón Semanal: En términos generales, el consumo energético no presenta variaciones significativas entre días de la semana, lo cual indica un patrón de demanda relativamente constante.

La Zona 1 mantiene el nivel más alto y estable de consumo diario, aunque registra un leve incremento los días martes y jueves, posiblemente asociado a dinámicas laborales o comerciales específicas.

La Zona 2 muestra una ligera disminución del consumo durante el fin de semana (sábado y domingo), lo que podría asociarse a una reducción en la actividad productiva o en el uso de ciertos servicios.

Finalmente, la Zona 3 exhibe un consumo bajo, uniforme y sin variaciones destacables, lo cual refuerza la hipótesis de que corresponde a un sector con baja demanda energética, potencialmente residencial de baja densidad o con menor actividad industrial.



III. Análisis Multivariado y Reducción de Dimensionalidad (PCA)

El Análisis de Componentes Principales (PCA) se aplicó para reducir la dimensionalidad de las variables interdependientes (consumo y clima).

A. PCA Global

El Scree Plot confirma que los dos primeros Componentes Principales (PC) concentran el 70.52% de la varianza total.

Tabla 3: Porcentaje de varianza explicada por los compontes del PCA

Componente	Varianza Explicada (%)	Varianza Acumulada (%)
PC1	51.61	51.61
PC2	18.91	70.52

PC1: Representa el factor general de "Demanda Térmica y Agregada", dominado por los pesos de las tres variables de Consumo y la Temperatura.

PC2: Funciona como un componente de "Variabilidad Atmosférica Residual", relacionado principalmente con la Humedad.

B. PCA Detallado por Zona

El PCA individual por zona ratifica la estructura: en las tres zonas, la varianza es similar y el Componente 1 establece consistentemente la relación directa entre el Consumo y la Temperatura.

```
=====
♦ Análisis PCA para Zone 1
=====
Componente 1: 50.44% de varianza explicada (acumulada: 50.44%)
Componente 2: 22.50% de varianza explicada (acumulada: 72.94%)
Componente 3: 17.81% de varianza explicada (acumulada: 90.75%)
Componente 4: 9.25% de varianza explicada (acumulada: 100.00%)

Ecuaciones de los componentes principales:

Componente Principal 1 = 0.615·'Temperature' + -0.468·'Humidity' + 0.428·'Wind Speed' + 0.469·'Zone 1 Power Consumption'
Componente Principal 2 = 0.102·'Temperature' + 0.487·'Humidity' + 0.786·'Wind Speed' + -0.366·'Zone 1 Power Consumption'
Componente Principal 3 = -0.057·'Temperature' + 0.648·'Humidity' + -0.041·'Wind Speed' + 0.759·'Zone 1 Power Consumption'
Componente Principal 4 = 0.78·'Temperature' + 0.353·'Humidity' + -0.444·'Wind Speed' + -0.266·'Zone 1 Power Consumption'

=====
♦ Análisis PCA para Zone 2
=====
Componente 1: 49.50% de varianza explicada (acumulada: 49.50%)
Componente 2: 23.05% de varianza explicada (acumulada: 72.54%)
Componente 3: 17.78% de varianza explicada (acumulada: 90.32%)
Componente 4: 9.68% de varianza explicada (acumulada: 100.00%)

Ecuaciones de los componentes principales:

Componente Principal 1 = 0.614·'Temperature' + -0.484·'Humidity' + 0.433·'Wind Speed' + 0.45·'Zone 2 Power Consumption'
Componente Principal 2 = 0.139·'Temperature' + 0.439·'Humidity' + 0.764·'Wind Speed' + -0.452·'Zone 2 Power Consumption'
Componente Principal 3 = -0.097·'Temperature' + 0.651·'Humidity' + 0.086·'Wind Speed' + 0.748·'Zone 2 Power Consumption'
Componente Principal 4 = 0.771·'Temperature' + 0.387·'Humidity' + -0.471·'Wind Speed' + -0.183·'Zone 2 Power Consumption'

=====
♦ Análisis PCA para Zone 3
=====
Componente 1: 51.75% de varianza explicada (acumulada: 51.75%)
Componente 2: 21.69% de varianza explicada (acumulada: 73.44%)
Componente 3: 17.48% de varianza explicada (acumulada: 90.93%)
Componente 4: 9.07% de varianza explicada (acumulada: 100.00%)

Ecuaciones de los componentes principales:


Componente Principal 1 = 0.61·'Temperature' + -0.427·'Humidity' + 0.454·'Wind Speed' + 0.49·'Zone 3 Power Consumption'
Componente Principal 2 = -0.023·'Temperature' + 0.769·'Humidity' + 0.629·'Wind Speed' + 0.116·'Zone 3 Power Consumption'
Componente Principal 3 = -0.071·'Temperature' + 0.29·'Humidity' + -0.506·'Wind Speed' + 0.809·'Zone 3 Power Consumption'
Componente Principal 4 = 0.789·'Temperature' + 0.379·'Humidity' + -0.378·'Wind Speed' + -0.302·'Zone 3 Power Consumption'
```

IV. Detección y Tratamiento de Atípicos

Se utilizaron los métodos IQR y Z-Score para cuantificar y analizar los valores extremos, afectando al 2.83% de las filas del dataset.

Tabla 4: Cuantificación de Valores Atípicos (Método IQR)

Variable	Total Atípicos	Justificación
Consumo Zona 3	1,191	Picos de demanda extremos (límite superior).
Humidity	291	Valores de baja humedad (límite inferior).
Temperature	142	Temperaturas muy altas (límite superior).
Consumo Zonas 2	7	Mínima presencia de atípicos.
Consumo Zona 1	0	No existen atípicos.



Estrategia de Tratamiento:

Los valores atípicos se consideran eventos genuinos del sistema (picos de demanda y temperaturas extremas) y no errores de registro. Por lo tanto, no se eliminan. En su lugar, su impacto será mitigado en la siguiente fase de preprocesamiento mediante la estandarización.

B. Preprocesamiento de Datos (Imputación, Escalamiento y Transformación):

Esta etapa se centra en homogeneizar la escala de las variables y transformar los datos categóricos para optimizar el rendimiento de los futuros modelos predictivos.

I. Imputación de Datos Faltantes

Se realizó una verificación exhaustiva de los valores nulos en el conjunto de datos.

`data.isnull().sum() = 0`

Conclusión: El dataset se encuentra completo, sin valores nulos en ninguna de las 8 variables. Esto es un indicador de la alta calidad del proceso de recolección de datos por parte de los sensores. Por lo tanto, la etapa de imputación no es necesaria y se procede directamente al escalamiento.

II. Escalamiento de Variables Numéricas

Las variables numéricas (Consumo, Temperatura, Humedad, etc.) operan en escalas muy diferentes, lo que podría sesgar modelos basados en distancia (como K-Means o PCA).

Técnica Aplicada: StandardScaler

Se aplicó la Estandarización a todas las variables numéricas. Este método transforma los datos para que tengan una media μ de cero y una desviación estándar σ de uno.

Justificación: StandardScaler es ideal porque preserva la forma de la distribución original, es menos sensible que otros métodos a los valores atípicos (que se decidió conservar) y es el preprocesamiento estándar para modelos basados en la distancia.

Variables Estandarizadas: Hour, Temperature, Humidity, Wind Speed, Zone 1 Power Consumption, Zone 2 Power Consumption, Zone 3 Power Consumption.

III. Transformación de Variables Categóricas

La variable Day (Día de la semana) es una variable categórica nominal que no tiene un orden inherente (ej. Lunes no es "mejor" que Viernes).

Técnica Aplicada: Codificación One-Hot (One-Hot Encoding)

Se transformó la columna Day en variables binarias (Day_Lunes, Day_Martes, etc.) utilizando la técnica One-Hot Encoding con `drop_first=True`.

Justificación: Esto evita que el modelo infiera una relación ordinal o lineal incorrecta a partir de etiquetas numéricas. Al usar `drop_first=True`, se crea una columna menos, ya que el día faltante (el día base, en este caso, Domingo) queda implícito cuando todas las demás columnas de día son cero. El dataset final cuenta con 13 columnas (7 numéricas escaladas + 6 variables binarias para los días).

Decisión Crítica sobre Hour:

Aunque la variable Hour es cíclica (23:00 sigue a 00:00), se optó por mantenerla en su formato numérico escalado en lugar de aplicar One-Hot Encoding. La alternativa habría creado 24 columnas, aumentando innecesariamente la dimensionalidad y el costo computacional. El escalamiento mitiga suficientemente el impacto de su magnitud para el modelado inicial.

CONCLUSIONES

Esta sección resume los principales aportes del trabajo, identifica las limitaciones inherentes al análisis realizado y propone extensiones futuras para maximizar el valor predictivo del dataset.

A. Contribuciones Principales del Estudio

El presente trabajo estableció una base sólida para el entendimiento y la predicción del consumo de energía en la ciudad de Tetuán. Las contribuciones clave incluyen:

-
-
- I. Identificación de Factores Determinantes:** Se confirmó formalmente que la Temperatura es el principal driver correlacionado linealmente con el consumo de energía en las tres zonas. Adicionalmente, se caracterizó con precisión el Pico de Demanda Vespertino (19:00 a 21:00 h) como el patrón estructural diario más relevante.
 - II. Preparación de Datos de Alta Calidad:** Se garantizó la integridad del dataset al confirmar la ausencia de valores faltantes y se aplicaron transformaciones robustas (StandardScaler y One-Hot Encoding). Esto prepara el conjunto de datos para cualquier modelo de Machine Learning, mitigando el impacto de las diferentes escalas de medición y los picos de consumo atípicos (tratados como eventos reales del sistema).
 - III. Simplificación del Sistema:** Mediante el Análisis de Componentes Principales (PCA), se demostró que el 70.52% de la varianza total del sistema (consumo y clima) puede explicarse por solo dos componentes, lo que valida la posibilidad de modelos predictivos simplificados y eficientes.

B. Limitaciones del Análisis

Si bien el análisis exploratorio y el preprocesamiento fueron exhaustivos, el estudio presenta limitaciones que deben ser consideradas en la etapa de modelado:

- I. Simplificación de la Temporalidad Horaria:** La variable Hour, siendo cíclica (23:00 sigue a 00:00), fue tratada únicamente con escalamiento. Esta simplificación podría hacer que modelos lineales no capturen con precisión la relación no lineal que existe entre la hora del día y el consumo de energía.
- II. Ausencia de Variables Externas:** El análisis se limitó a las variables internas (clima y consumo). No se incorporaron factores externos que influyen decisivamente en el consumo agregado, tales como días festivos, vacaciones escolares, eventos deportivos masivos o cambios regulatorios en la tarifa eléctrica.
- III. Énfasis en la Linealidad:** Aunque el PCA fue útil, se centró en la varianza explicada por relaciones lineales. Esto puede subestimar la complejidad de las interacciones no lineales entre las variables climáticas (ej. el efecto combinado de calor extremo y humedad alta).

C. Líneas de Mejora y Extensión Futura

Para superar las limitaciones y profundizar en el entendimiento de la demanda energética, se proponen las siguientes líneas de investigación y desarrollo:

- I. Ingeniería de Características Cíclicas:** Aplicar técnicas avanzadas de feature engineering (e.g., transformación de senos y cosenos) a la variable Hour para representar su naturaleza cíclica de manera más precisa, mejorando la capacidad predictiva de los modelos.

-
-
- II. **Modelado de Series de Tiempo Avanzado:** Explorar modelos de Deep Learning especializados en series de tiempo, como las Redes Neuronales Recurrentes (LSTM) o GRU, que están diseñadas para capturar las dependencias temporales y las secuencias de eventos del consumo.
 - III. **Integración de Datos Socioeconómicos y Eventuales:** Enriquecer el dataset mediante la incorporación de variables externas como un calendario de días festivos y variables socioeconómicas (crecimiento poblacional o actividad industrial), lo que permitiría construir modelos más robustos y con mayor capacidad de generalización.
 - IV. **Análisis de Segmentación de Clientes:** Utilizar los resultados del PCA y el análisis de consumo para aplicar algoritmos de Clustering (ej. K-Means) sobre los patrones de consumo, identificando distintos perfiles de clientes para cada zona (residencial, comercial, industrial) y optimizando la gestión de la demanda.

REFERENCIAS

1. LEE, Y., PAREDES, J. R., & LEE, S. H. (2012). *LAS REDES INTELIGENTES DE ENERGÍA Y SU IMPLEMENTACIÓN EN CIUDADES SOSTENIBLES* (NOTA TÉCNICA IDB-TN-446). BANCO INTERAMERICANO DE DESARROLLO.
2. RUEDA BAYONA, JUAN GABRIEL, ELLES PÉREZ, CINDY JUDITH, SÁNCHEZ COTTE, EDGAR HUMBERTO, GONZÁLEZ ARIZA, ÁNGEL LEÓN, & RIVILLAS OSPINA, GERMÁN DANIEL. (2016). IDENTIFICACIÓN DE PATRONES DE VARIABILIDAD CLIMÁTICA A PARTIR DE ANÁLISIS DE COMPONENTES PRINCIPALES, FOURIER Y CLÚSTER K-MEDIAS. *TECNURA*, 20(50), 55-68. [HTTPS://DOI.ORG/10.14483/UDISTRITAL.JOUR.TECNURA.2016.4.A04](https://doi.org/10.14483/UDISTRITAL.JOUR.TECNURA.2016.4.A04)
3. SALAM, A. & EL HIBAOU, A. (2018). POWER CONSUMPTION OF TETOUAN CITY [DATASET]. UCI MACHINE LEARNING REPOSITORY. [HTTPS://DOI.ORG/10.24432/C5B034](https://doi.org/10.24432/C5B034).
4. PEDREGOSA, F., VAROQUAUX, G., GRAMFORT, A., MICHEL, V., THIRION, B., GRISEL, O., BLONDEL, M., PRETTENHOFER, P., WEISS, R., DUBOURG, V., VANDERPLAS, J., PASSOS, A., COURNAPEAU, D., DELEHELLE, M., SIBOMANA, J., JOSEPH, P., & ZAIDOUNI, M. (2011). SCIKIT-LEARN: MACHINE LEARNING IN PYTHON. *JOURNAL OF MACHINE LEARNING RESEARCH*, 12, 2825–2830. RECUPERADO DE [HTTPS://SCIKIT-LEARN.ORG/](https://scikit-learn.org/)
5. PANDAS DEVELOPMENT TEAM. (2024). PANDAS: POWERFUL DATA STRUCTURES FOR DATA ANALYSIS, TIME SERIES, AND STATISTICS (VERSIÓN 2.2.0) [SOFTWARE]. PANDAS SOFTWARE FOUNDATION. RECUPERADO DE [HTTPS://PANDAS.PYDATA.ORG/](https://pandas.pydata.org/)
6. WASKOM, M. L. (2021). SEABORN: STATISTICAL DATA VISUALIZATION. *JOURNAL OF OPEN SOURCE SOFTWARE*, 6(60), 3021. [HTTPS://DOI.ORG/10.21105/JOSS.03021](https://doi.org/10.21105/joss.03021)